


Introducción al Aprendizaje Automático

Felipe Ramírez Herrera



Perfil del profesor



Felipe Ramírez Herrera

Ingeniero / Emprendedor

Banca / Seguridad Nacional

“Más allá de la tecnología, me interesa cómo las herramientas IA pueden ser usadas de forma responsable, eficiente y alineada con las necesidades reales de las organizaciones”

Gerente General de **Auricom Research S.R.L**, empresa fundada con el objetivo de desarrollar soluciones tecnológicas que contribuyan a la prevención del fraude y el análisis de riesgos complejos.

Experiencia en el sector público como en el privado, liderando equipos de tecnología, innovación y analítica avanzada.

Inteligencia Artificial Avanzada y Aplicada

Universitat de València

BigData & Analytics

Universidad Politécnica de Cataluña

Inteligencia Artificial

Universidad Internacional de la Rioja

Cloud Computing

Universidad Politécnica de Cataluña

Data Management

Universidad de Barcelona

Ingeniería en Computación

Instituto Tecnológico de Costa Rica

Agenda


- 
- 
- 
- ▶ **1** Contexto
 - 2** Historia
 - 3** Concepto de aprendizaje automático
 - 4** Modelos: Tareas, Experiencias y Desempeño
 - 5** Laboratorio y Práctica
 - 6** Preguntas y comentarios

Interrupciones en la industria

Cambio tecnológico y social.

Industria 1.0

c. 1780




Mecanización

Producción industrial basada en máquinas alimentadas por agua y vapor.

Industria 2.0

c. 1870




Electrificación

Producción en masa basada en la línea de montaje.

Industria 3.0

c. 1970




Automatización

Automatización basada en electrónica y computación.

Industria 3.5

c. 1980




Globalización

Deslocalización de la producción a economías de bajo costo.

Comunicación y movilización.

Industria 4.0

c. 2011




Digitalización

Introducción de tecnologías digitales.

Internet of Things
Big Data / Fast Data
Machine Learning / AI
Manufactura Aditiva
Robótica
Ecosistemas / API

Industria 5.0

Ahora




Valor social

Bienestar y prosperidad basadas en:

Sostenibilidad
Centrada en el ser humano
Desintegración y Resiliencia

General Purpose Technology J-curve: El caso de la electricidad y su impacto en la productividad




Vanguard supone que las tecnologías de propósito general tienden a exhibir dos estadios.

Algunos ejemplos:

- Electrificación (+10%)
- Uso de computación personal (+2.5%).

¿Qué nos espera con la IA?

Impacto en el trabajo y la eficiencia




AI Inteligencia Artificial E Electrificación. C Computadoras y tecnologías de información.

La **oferta curricular de las universidades** deberá considerar el impacto de la IA sobre la eficiencia en los diferentes grupos ocupacionales


No todos los grupos profesionales se verán impactados de la misma forma:

Se preveé:

- Algunos trabajos no serán impactados.
- Labores relacionadas con tecnología de información se verán mediamente impactadas con capacidades aumentadas.
- Depende del uso de información como insumo de los procesos.



La inteligencia artificial se está volviendo esencial para el éxito... pero no siempre se obtienen los beneficios prometidos.




72% de las organizaciones no han logrado adoptar y escalar con éxito.

Los desafíos incluyen:


- **Difícil transición de pilotos a productos.**
- Fallos en los modelos en producción.
- Estancamiento de la productividad del equipo.
- Limitaciones en la protección contra posibles riesgos derivados de variables desconocidas.
- **Datos de mala calidad o insuficientes.**

Qué nos dicen las redes sociales sobre IA...?



Inteligencia artificial

Es uno de los múltiples campos de las ciencias de la computación.



Statistical vs Machine Learning

Ambos son utilizados en el reconocimiento de patrones, identificación de valores extremos, descubrimientos de indicios y minería de datos.

Statistical Learning

- Énfasis en la disciplina
- Se apalanca en la inferencia
- Se fundamenta en la estimación.

El modelado estadístico analiza las características (features) y los puntos de datos en la forma de ecuaciones matemáticas.


Machine Learning

- Énfasis en la realización.
- Se apalanca en la velocidad / computación.
- Se fundamenta en la mejora perpetua.

Busca evolucionar a través del tiempo mediante algoritmos dinámicos sin la dependencia en conjuntos predefinidos de reglas o programas.

Next-Gen Data Technologies

Más allá del Hype, existen oportunidades que pueden explotarse ahora.



Industrialización



Implementación in-house




Adopción de base tecnológica de terceros



Implementación por incubación

La IA es mucho más amplia que la GenAI, y muchas organizaciones ahora parecen estar listas para explorar todo el espectro de técnicas y prácticas de IA.



¿Ingeniería de IA?

Es fundamental para entregar soluciones de IA y GenAI a gran escala.


- Unifica DataOps, MLOps y DevOps.
- Esta disciplina estandariza y optimiza el ciclo de vida de los sistemas de IA.
- Facilita la reutilización de artefactos de IA y permite la orquestación de soluciones.

Lapso para la adopción general: ○ Menos de 2 años ● 2 - 5 años ● 5 - 10 años ▲ +10 años ● Obsoleto



El lado oscuro: Puede la IA reflejar el peor lado humano?

Historia de la inteligencia artificial




NOTA: MIT = Massachusetts Institute of Technology.

Historia de la inteligencia artificial




Mainframes

1953 - IBM 701 Defense Calculator Mainframe



Semiconductores y microprocesadores

1971 - Intel 4004
(Primer Microprocesador)



Big Data

1998 - John Mashey
Populariza el término "big data"



Almacenamiento y procesamiento en la nube

2006 - Lanzamiento de Amazon Web Services



Internet de las cosas

2008 - Existen más objetos o cosas que personas conectadas a internet

Ciencia Ficción

Primavera de AI

Invierno IA

Primavera de AI

Invierno IA

Primavera de AI

1950s

- **Alan Turing** publica Computing Machinery and Intelligence y propone el marco lógico para construir máquinas inteligentes y cómo probarlas (imitation game)

1960s

- Financiamiento de **DARPA** para centros académicos.
- Newell y Simon proponen el **General Problem Solver**.
- Weizenbaum propone el programa **ELIZA**.

1970s

- La **falta de poder computacional** limita el progreso de las tecnologías de inteligencia artificial.
- Se agotan las fuentes de financiamiento.

1980s

- Hopfield y Rumelhart popularizan el concepto de **Deep Learning**.
- El gobierno japonés invierte 400 MM USD en inteligencia artificial y tecnologías afines.

1990s

- IBM **Deep Blue** derrota a Garry Kasparov en ajedrez.
- Se implementa el sistema de reconocimiento de voz de **Dragon Systems**.

2000s

- El robot de Stanford gana el **DARPA Grand Challenge**.
- Geoffrey Hinton y otros repopularizan el concepto de **backpropagation** para redes profundas.
- Google Brain (2009) utiliza **GPUs** para sus redes neuronales.

¿Qué es diferente ahora?

- **Avances tecnológicos:** Se habilitan tecnologías que proveen los datos y el acceso poder de procesamiento barato que no era posible durante los inviernos anteriores.
- **Talento y enfoque:** El desarrollo del AI esta dirigido hoy mayoritariamente por tecnólogos más que por académicos, los ingenieros de software construyen aplicaciones reales que van más allá de pruebas de concepto.
- **Liderazgo e inversión:** Las grandes empresas tecnológicas, con rentabilidad inmediata, invierten fuertemente en IA, demostrando que esas tecnologías aumentan la rentabilidad.

¿Qué es lo que viene?

- **Transfer Learning:** La falta de abstracción de las tecnologías actuales, impide que el conocimiento y las lecciones aprendidas puedan tomarse de un área y llevarse a otras.
- **Efficient Deep Learning:** Reducir el esfuerzo para entrenar modelos y automatizar la extracción de características.
- **Unstructured Learning:** En la búsqueda de la inteligencia artificial general, el uso de RL y la simulación habilitan nuevas áreas de aplicación.

Humano | Racional y Pensar | Comportarse

Algunos consideran la inteligencia como una propiedad de los procesos de pensamiento y razonamiento internos, mientras que otros se centran en el comportamiento inteligente, una caracterización externa.

Actuar como humanos

Prueba de Turing

- Procesamiento del lenguaje natural.
- Representación del conocimiento.
- Razonamiento automatizado.
- Aprendizaje automático.

Prueba de Turing total

- Visión artificial y reconocimiento de voz.
- Robótica para manipular objetos y moverse.



Pensar como humanos

Modelo cognitivo

- Introspección: tratar de captar nuestros propios pensamientos a medida que pasan.
- Experimentos psicológicos: observar a una persona en acción.
- Imágenes cerebrales: observación del cerebro en acción.



Actuar racionalmente

Lógica

- Requiere un conocimiento cierto del mundo, una condición que, en realidad, rara vez se logra.

Probabilidad

- Complementa la lógica permitiendo un razonamiento riguroso con información incierta.



Pensar racionalmente (modelo estándar)

Agentes

- Puedan tomar decisiones bajo incertidumbre para lograr el mejor resultado esperado.


Modelo

- Se ha centrado en el estudio de "hacer lo correcto" y la construcción de agentes que hagan lo correcto.




Neurociencia / Psicología Cognitiva

¿Qué es la mente? ¿Qué implica la cognición y el aprendizaje? ¿Cómo se representa el conocimiento?



Modelo Cartesiano Clásico


El modelo cartesiano clásico de la mente bajo el cual el cuerpo, el mundo, la percepción y la acción se entienden como independientes.



Modelo Corporizado


El modelo cognitivo de la mente bajo el cual el cuerpo, el mundo, la percepción y la acción se relacionan dinámicamente entre sí.

Tipos de inteligencia artificial




La estructura de las habilidades mentales.

El factor g es común a todas las pruebas mentales. Los números son correlaciones que muestran la fuerza de la relación entre las pruebas, los factores y g . Nótese que todas las correlaciones son positivas. Adaptado de Deary et al. (2010).



Programación vs. Aprendizaje Automático

Un programa en Python o R no necesariamente es aprendizaje automático.



¿Es RPA un ejemplo de Machine Learning o no? ¿Automatización vs Hiper-automatización?

Inteligencia artificial débil o fuerte?

¿Qué es la IA débil? (Weak AI / Narrow AI)

Respuestas similares a las humanas basándose en algoritmos de programación.

No está "pensando", simplemente parece estarlo.


Ejemplos: Siri, Cortana y Alexa.



NLP



Speech Recognition



Object Recognition






Image Clasification



Reforzamiento



Recomentación

¿Qué es la IA fuerte? (Strong AI / General AI)

Cualquier sistema que pueda pensar por sí mismo.

Razonar, aprender, planificar, comunicarse, emitir juicios y tener cierto nivel de autoconciencia.

No simula la mente humana, es una mente (en teoría).

Singularidad o Superinteligencia.


No hay ejemplos.

Tendencias en Machine Learning y Ciencia de Datos

De acuerdo al Gartner Hype Cycle for Data Science & Machine Learning (Julio, 2021).

Prestar atención a:

Predictive Analytics
Explainable AI
MLOps
Deep Learning
Graph Analytics
Event Stream Processing




Tendencias en Inteligencia Artificial

De acuerdo al Gartner Hype Cycle for Artificial Intelligence (Julio, 2021).

Prestar atención a:


Machine Learning
Deep Learning
AI Cloud Services
Graph Analytics
Lenguaje Natural



Evolución del aprendizaje

Una máquina con conciencia, sensibilidad y mente que se acerca a las habilidades cognitivas humanas es aún un concepto teórico (inteligencia artificial general, año 2040).


AI Inteligencia Artificial



Las máquinas imitan las funciones cognitivas asociadas con las mentes humanas.

Incluye todos los aspectos de aprendizaje, percepción, resolución de problemas y razonamiento.

ML Aprendizaje automático




Aprendizaje y la realización de predicciones basadas en datos y experiencias aprendidas.

Comprende varias categorías que incluyen:

- 1) Supervisado
- 2) Semi-supervisado
- 3) No supervisado

DL Aprendizaje profundo



Los algoritmos modelan abstracciones de alto nivel en los datos. Conecta múltiples niveles de neuronas artificiales.

Las redes neuronales reciben, analizan y determinan entradas y son informadas si la determinación de la salida es correcta.


RL Aprendizaje por reforzamiento



Inspirada en la psicología conductista, cuya ocupación es determinar qué acciones debe escoger un agente de software en un entorno dado con el fin de maximizar alguna noción de "recompensa" o premio acumulado.

Diferenciar el Deep Learning

Es una forma especializada de aprendizaje automático, pero no todo aprendizaje automático basado en redes o grandes datos es aprendizaje profundo.



Un flujo de trabajo de aprendizaje automático comienza con la extracción manual de características relevantes de las imágenes. Luego, las características se utilizan para crear un modelo que categoriza los objetos en la imagen.




Con un flujo de trabajo de aprendizaje profundo, las características relevantes se extraen automáticamente de las imágenes. Además, el aprendizaje profundo realiza un "aprendizaje de extremo a extremo", donde una red recibe datos sin procesar y una tarea para realizar, como la clasificación, y aprende cómo hacerlo automáticamente.

Shallow Learning

Los algoritmos de aprendizaje profundo se escalan con los datos, mientras que el aprendizaje superficial converge.


Una ventaja clave de las redes de aprendizaje profundo es que a menudo continúan mejorando a medida que aumenta el tamaño de sus datos.



El aprendizaje superficial se refiere a los métodos de aprendizaje automático que se estancan en un cierto nivel de rendimiento cuando agrega más ejemplos y datos de entrenamiento a la red.

Operacionalización de modelos


Requiere una serie de pasos una vez que el modelo ha sido desarrollado. Estos son cruciales para el éxito del modelo.



En muchos sentidos, estos pasos forman parte de una disciplina de la misma manera que DevOps es una disciplina para el desarrollo de software. De hecho, las empresas exitosas y analíticamente maduras ponen en producción los modelos y se aseguran de que funcionen sin problemas, tal como lo hacen con cualquier pieza de software. Las organizaciones a menudo llaman al grupo que operacionaliza los modelos ModelOps, DevOps, MLOps, ingeniería analítica o ingeniería de producción.

Formas de razonamiento

El desarrollo de agentes inteligentes, busca incorporar la mayoría de las formas de razonamiento.



Razonamiento Inductivo

Busca casos y datos para producir un patrón o regla.

Caso



Generalización (caso)



Regla general

Ejemplo:

José es humano



José es mortal



Todos los humanos son mortales



Razonamiento Deductivo

Toma una regla general y observa si se cumple en un caso particular.

Conclusión específica



Predicción (caso)



Regla general

Ejemplo:

Todos los humanos son mortales



José es humano



José es mortal



Razonamiento Abductivo

Crea una explicación tentativa que tenga sentido para observaciones o casos en los cuales no hay explicación o regla en la base de conocimientos.

Conclusión tentativa



Mejor predicción (caso)



Regla incompleta

Ejemplo:

Todos los humanos son mortales



José es mortal



José es humano


Aprendizaje Automático

Permite a los agentes inteligentes aprender de experiencias, tutoriales o simuladores.

El aprendizaje automático es un área de la inteligencia artificial que ajusta modelos matemáticos a los datos observados.

Puede dividirse a grandes rasgos en aprendizaje supervisado, aprendizaje no supervisado y aprendizaje por refuerzo.

Las redes neuronales profundas contribuyen a cada una de estas áreas.




El aprendizaje de representación (Representation Learning) es el avance conceptual más importante de la última década en la inteligencia artificial, y es exactamente lo que le da su nombre y poder al Deep Learning (Aprendizaje Profundo). El modelo ajusta sus parámetros para aprender su propia forma de “ver” y representar el mundo, descubriendo a menudo patrones sutiles que los humanos jamás habrían imaginado. El Deep Learning no es más que aprendizaje de representaciones jerárquicas.

Algoritmo de aprendizaje automático

Un algoritmo de aprendizaje automático es un algoritmo que es capaz de aprender a partir de los datos. Pero, ¿qué entendemos por aprender? Mitchell (1997) ofrece una definición sucinta:

“ Se dice que un programa informático **aprende** de la *experiencia* E con respecto a alguna clase de *tareas* T y medida de rendimiento P, si su *rendimiento* en las tareas de T, según lo medido por P, mejora con la experiencia E.



Los **parámetros** son las variables internas que el modelo ajusta de forma autónoma durante su fase de entrenamiento. Representan el "conocimiento" o la memoria matemática que el algoritmo ha extraído de los datos.

Algoritmo de aprendizaje automático: La tarea

Un algoritmo de aprendizaje automático es un algoritmo que es capaz de aprender a partir de los datos. Pero, ¿qué entendemos por aprender? Mitchell (1997) ofrece una definición sucinta:

Las **tareas** de aprendizaje automático generalmente se describen en términos de cómo el sistema de aprendizaje automático debe procesar un **ejemplo**.

Un **ejemplo** es una colección de **características** que han sido medidas cuantitativamente a partir de algún objeto o evento que queremos que procese el sistema de aprendizaje automático.

Por lo general, representamos un **ejemplo** como un **vector** de los números reales donde cada entrada del vector es otra característica.


Por ejemplo, las características de una imagen son generalmente los valores de los píxeles de la imagen.

Algoritmo de aprendizaje automático: La tarea

Los algoritmos (cc. modelos) actúan como "cajas negras" que reciben datos del mundo real (como texto, audio o imágenes) codificados como vectores numéricos y devuelven otro vector numérico que se traduce en una predicción útil.

Se ilustran distintos tipos de problemas:


- **Regresión:** El modelo devuelve un valor numérico continuo. Un ejemplo es predecir el precio de una casa basándose en sus características, como el tamaño y el número de habitaciones.
- **Regresión multivariable:** El modelo predice más de un valor continuo a la vez, como calcular los puntos de congelación y ebullición a partir de la estructura química de una molécula.
- **Clasificación binaria:** El modelo asigna la entrada a una de dos categorías posibles, devolviendo las probabilidades de pertenecer a cada una. Un ejemplo es determinar si la reseña de un restaurante es positiva o negativa.
- **Clasificación multiclase:** El modelo clasifica la entrada en una de $N > 2$ categorías, devolviendo un vector con las probabilidades para cada una de las N opciones. Ejemplos de esto incluyen identificar el género musical de una pista de audio o reconocer qué objeto específico aparece en una imagen.




Experiencias de Aprendizaje Automático

El contar con datos etiquetados para lograr el aprendizaje, permite diferenciar las diferentes formas en las que un agente inteligente aprende.


Supervisado



No supervisado



Semi-supervisado




Autosupervisado

Simbología: ● Etiqueta A ● Etiqueta B ● Sin etiqueta ? Objetivo

Aprendizaje por reforzamiento


Permite a los agentes inteligentes aprender de experiencias, tutoriales o simuladores.



	Aprendizaje supervisado	Aprendizaje no supervisado	Aprendizaje por reforzamiento
Datos requeridos para entrenamiento	Datos etiquetados	Datos sin etiquetar	Datos sintéticos creados cuando un agente interactúa con el ambiente y recibe retroalimentación.
Propósito	Predice la variable objetivo para observaciones sin etiquetar, basado en lo que ha aprendido de los datos etiquetados	Identifica grupos de datos que exhiben un comportamiento similar o excepcional.	Identifica una secuencia optima de acciones para alcanzar un resultado óptimo.
Adaptabilidad	Hay que reentrenar el modelo si las condiciones subyacentes cambia y causan drift o shift.	Re-ejecutar el algoritmo cuando ocurren cambios en los datos.	El sistema puede adaptarse por sí mismo (dentro de un cierto margen).

Algoritmo de aprendizaje automático: La medida de desempeño

Para evaluar las capacidades de un algoritmo de aprendizaje automático, debemos diseñar una medida cuantitativa de su rendimiento. Por lo general, esta medida de rendimiento P es específica para la tarea T que está llevando a cabo el sistema. Por ejemplo para un algoritmo de clasificación:



- **TP: Verdaderos Positivos (True Positives):** Ocurre cuando el modelo predice correctamente la clase "positiva" (la clase que estamos intentando detectar). Ejemplo: Un paciente tiene la enfermedad y el modelo médico predice que sí la tiene.
- **TN: Verdaderos Negativos (True Negatives):** Ocurre cuando el modelo predice correctamente la clase "negativa" (la ausencia de lo que estamos intentando detectar). Ejemplo: Un paciente no tiene la enfermedad y el modelo predice que no la tiene.
- **FP: Falsos Positivos (False Positives):** Ocurre cuando el modelo predice incorrectamente la clase "positiva", pero en la realidad es negativa. A esto también se le conoce en estadística como Error de Tipo I. Ejemplo: Un paciente no tiene la enfermedad, pero el modelo predice erróneamente que sí la tiene (una falsa alarma).
- **FN: Falsos Negativos (False Negatives):** Ocurre cuando el modelo predice incorrectamente la clase "negativa", pero en la realidad es positiva. A esto también se le conoce como Error de Tipo II. Ejemplo: Un paciente tiene la enfermedad, pero el modelo predice erróneamente que no la tiene (un caso que pasó desapercibido).

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

¿Cómo se interpreta el resultado de F1-Score? Siempre será un número entre 0 y 1.

Alto (Cerca de 1.0): Significa que tu modelo es robusto. Está atrapando la mayoría de las anomalías (Buen Recall) sin generar demasiadas falsas alarmas (Buena Precisión).

Bajo (Cerca de 0.0): Significa que tu modelo está fallando terriblemente en al menos una de las dos áreas, o en ambas.

Algoritmo de aprendizaje automático: La medida de desempeño

(a) Matriz de confusión binaria

		Etiqueta Real	
		Positivo	Negativo
Etiqueta Predicha	Positivo	Verdadero Positivo (TP)	Falso Positivo (FP)
	Negativo	Falso Negativo (FN)	Verdadero Negativo (TN)

(b) Matriz de confusión multiclase

		Etiqueta Real		
		Clase A	Clase B	Clase C
Etiqueta Predicha	Clase A	1 TP _A (A como A)	2 Error _{BA} (B como A)	3 Error _{CA} (C como A)
	Clase B	4 Error _{AB} (A como B)	5 TP _B (B como B)	6 Error _{CB} (C como B)
	Clase C	7 Error _{AC} (A como C)	8 Error _{BC} (B como C)	9 TP _C (C como C)

Ejercicio (20 min): El Filtro de Spam


Imagina que recibimos 100 correos electrónicos en total. Nosotros sabemos la verdad (Realidad): 20 correos son realmente Spam y 80 correos son correos legítimos (No Spam).

Pasamos estos 100 correos por nuestro modelo (Predicción), y esto es lo que ocurre: De los 20 correos Spam, el modelo atrapa 15 y los manda a la carpeta de Spam, pero se le escapan 5 que terminan en la bandeja de entrada. De los 80 correos legítimos, el modelo deja 70 tranquilos en la bandeja de entrada, pero se equivoca con 10 y los manda a la carpeta de Spam por error.

Elabora la matriz de confusión, evalúa accuracy, recall y F1-Score



Actuación orientada por inteligencia: Modelo 3i (Ratcliffe, 2005)



Interpretar

Los analistas de inteligencia deben tener las capacidades y las competencias para interpretar un entorno complejo como un medio de maximizar las opciones para la intervención y comparación para los resultados de análisis.

Influenciar

Los analistas de inteligencia deben tener las capacidades y competencias para influenciar a los tomadores de decisiones sobre la intervención y utilización de los recursos.

Impactar

Los tomadores de decisiones deben estar capacitados para intervenir y producir un impacto sobre el entorno.

Laboratorio 1: Modelos

Iris Dataset.

- RandomForest
- KNN y SVM
- Normalización y MLP
- DNN con Pytorch***

Comparemos los modelos.



Ejercicio Práctico(10 min)

Adapte lo visto anteriormente para el conjunto de datos de ejemplo Wine.

```
import pandas as pd  
import matplotlib.pyplot as plt  
import seaborn as sns  
from sklearn.datasets import load_wine
```

```
wine = load_wine()
```



Generalización

La generalización es la capacidad de un modelo para realizar predicciones precisas y comportarse adecuadamente frente a datos nuevos y nunca antes vistos (es decir, datos que no formaron parte de su proceso de entrenamiento).

Objetivo:

Cuando un algoritmo aprende, evaluamos su éxito utilizando dos métricas principales:

Error de entrenamiento (Training Error):

Mide los errores cometidos en los datos específicos utilizados para enseñar al modelo.

Error de generalización o prueba (Test Error):

Mide los errores cometidos en datos no vistos previamente.

Desafíos comunes:

Sobreajuste (Overfitting): Funciona a la perfección en el entrenamiento, pero falla con datos nuevos.

Subajuste (Underfitting): Tiene un rendimiento deficiente tanto en los datos de entrenamiento como en los de prueba.

El objetivo es encontrar el punto de equilibrio matemático donde la brecha entre el error de entrenamiento y el de prueba se minimice, maximizando así la precisión predictiva.

Regularización

Técnicas que penalizan los modelos excesivamente complejos, fomentando pesos de parámetros más simples.

Abandono (Dropout)

Una técnica en la que se “apagan” neuronas al azar durante el entrenamiento para evitar que la red neuronal dependa demasiado de rutas o detalles específicos.

Aumento de datos (Data Augmentation)

Agregar ligeras variaciones, ruido o transformaciones a los datos de entrenamiento, haciendo que el modelo sea más robusto ante anomalías del mundo real.

Parada temprana (Early Stopping)



Detener el proceso de entrenamiento tan pronto como el error en un conjunto de datos de validación comienza a aumentar, evitando que el modelo se optimice en exceso para los datos de entrenamiento.

Validación cruzada (Cross-Validation)

Dividir los datos en múltiples subconjuntos para probar repetidamente cómo se comporta el modelo con entradas no vistas antes de su implementación final.

Función de pérdida (loss)

Una función de pérdida (loss function) es una fórmula matemática que cuantifica la diferencia entre la salida predicha por un modelo y el valor real o “verdad fundamental” (ground truth).




Sirve como un mecanismo de retroalimentación que le indica al modelo qué tan “erradas” son sus predicciones, siendo el objetivo final del entrenamiento **minimizar** este valor.


Capacidad/Complejidad del modelo: Redes neuronales

También conocidas como sistemas conexionistas, se trata de un conjunto de unidades, llamadas neuronas artificiales, conectadas entre sí para transmitirse señales.

Entrenamiento ►
(Training)



Neuronas artificiales



Nota: Las redes neuronales "superficiales" son un término que se usa para describir NN que generalmente tienen solo una capa oculta en comparación con NN profundas que tienen varias capas ocultas, a menudo de varios tipos.

Fuentes de error: Ruido, Sesgo y Varianza

En pocas palabras, es la prueba de fuego de cualquier algoritmo es lograr la generalización. Es la diferencia entre aprender un concepto y memorizar las respuestas de un examen.

A

Ruido (Noise): Es el error inherente a los datos en sí. Ocurre porque el mundo real es impredecible, porque hay variables que no estamos midiendo o porque los datos están mal etiquetados. Es una barrera insuperable; no importa qué tan bueno sea tu modelo, nunca podrá predecir el ruido aleatorio en datos nuevos (test data).

B

Sesgo (Bias): Es el error que proviene de la rigidez del modelo. Sucede cuando el modelo que elegimos es demasiado simple para capturar la complejidad real del problema. Por ejemplo, intentar usar una simple línea recta para predecir un comportamiento que en realidad tiene forma de onda. El modelo no es lo suficientemente flexible, por lo que comete errores sistemáticos (Subajuste o Underfitting).


C

Varianza (Variance): Es el error que proviene de la hipersensibilidad del modelo. Sucede cuando tenemos datos de entrenamiento limitados y un modelo tan complejo que termina memorizando el ruido o las peculiaridades exactas de esos datos específicos, en lugar de aprender el patrón general. Si entrenaras el mismo modelo con un conjunto de datos ligeramente distinto, la predicción cambiaría drásticamente. (A esto también se le conoce como Sobreajuste u Overfitting).

La capacidad está directamente ligada a los parámetros. La capacidad del modelo se refiere al tamaño y la diversidad del conjunto de funciones matemáticas que el modelo es capaz de aprender y representar. En términos simples, es la "flexibilidad" o el "tamaño del cerebro" del algoritmo. Para entenderlo mejor, conectemos esto con los conceptos que acabamos de ver: 1) Capacidad Baja: Un modelo con baja capacidad solo puede entender relaciones muy simples y rígidas. Por ejemplo, una línea recta. Si le presentas un problema complejo (como el comportamiento de un mercado financiero), no tendrá la flexibilidad matemática para entenderlo. Esto resulta en Alto Sesgo (Subajuste). 2) Capacidad Alta: Un modelo con alta capacidad puede doblarse, torcerse y adaptarse a relaciones increíblemente complejas y no lineales. Sin embargo, si le das demasiada capacidad y no tienes suficientes datos, el modelo usará esa flexibilidad para memorizar el ruido y las anomalías de los datos de entrenamiento. Esto resulta en Alta Varianza (Sobreajuste). La regularización es una técnica matemática que utilizamos para evitar que un modelo sufra de sobreajuste (overfitting).

Sobreajuste, buen ajuste y subajuste

El subajuste (underfitting), el sobreajuste (overfitting) y el ajuste óptimo (best fit) describen qué tan bien un modelo de aprendizaje automático aprende los patrones de los datos de entrenamiento y los generaliza a datos nuevos y desconocidos. Lograr el ajuste óptimo requiere equilibrar la complejidad del modelo para evitar tanto el subaprendizaje rígido como la memorización caótica.




El **subajuste (underfitting)** ocurre cuando un modelo es demasiado simple y no logra capturar los patrones de los datos, generalmente por falta de capacidad algorítmica, escasez de variables o exceso de regularización. Se soluciona aumentando la complejidad del modelo, añadiendo características relevantes y reduciendo las restricciones de regularización.

El **sobreajuste (overfitting)** sucede cuando un modelo es tan complejo que memoriza los datos de entrenamiento (incluyendo el ruido) en lugar de aprender reglas generales, a menudo por usar muchos parámetros, pocos datos o entrenar en exceso. Para corregirlo, se deben usar más datos, simplificar la arquitectura del modelo, aplicar regularización o detener el entrenamiento a tiempo (early stopping).

El **ajuste óptimo (best fit)** es el equilibrio ideal en el que el modelo generaliza perfectamente ante datos nuevos, capturando la señal real y descartando el ruido. Se evidencia cuando los errores de entrenamiento y validación disminuyen a la par, estabilizándose en un punto mínimo con muy poca diferencia entre ambos.

Deriva (Data & Model Drifting)




Deriva (Data & Model Drifting)

La deriva de datos (data drift) y la deriva de concepto (concept drift) suelen ocurrir simultáneamente y la primera puede ser síntoma de la segunda, aunque no siempre es así.

Deriva de datos

Objetivo: ventas




Distribución de características: canal de ventas



Deriva de concepto

Objetivo: ventas



Distribución de características: canal de ventas



La deriva de concepto implica un cambio fundamental en los patrones de comportamiento.

En estos casos de deriva de concepto, los modelos creados previamente quedan prácticamente obsoletos.

Deriva (Data & Model Drifting)

Cuando se habla de deriva de datos (data drift), normalmente nos referimos a las características (features) de entrada que se introducen en el modelo. En cambio, la deriva de predicción (prediction drift) es el cambio en la distribución de las salidas (outputs) del modelo.



La deriva de predicción (prediction drift) puede indicar muchos problemas, desde entradas de datos de baja calidad hasta la deriva de concepto (concept drift) en el proceso modelado. Al mismo tiempo, la deriva de predicción no siempre implica el deterioro del modelo. También puede ocurrir si el modelo se adapta bien al nuevo entorno. La diferencia: la deriva de datos se refiere a los cambios en los datos de entrada del modelo, mientras que la deriva de predicción se refiere a los cambios en las salidas del modelo.

Laboratorio 2: Generalización

- Regresión (Polinomio)
- Clasificación (Cáncer)

