


Introducción al Aprendizaje Automático

Felipe Ramírez Herrera



EDA

El Análisis Exploratorio de Datos busca entender la “materia prima” de tu proyecto antes de aplicar modelos más complejos.

Sus funciones principales incluyen:

Resumir características: Obtener una visión general de cómo se distribuyen los datos. Detectar anomalías: Identificar valores atípicos (outliers) o datos faltantes y corruptos.

Encontrar patrones: Revelar tendencias ocultas y correlaciones entre diferentes variables.

Formular hipótesis: Generar nuevas preguntas e ideas basadas en lo que los datos revelan.





Diagrama de Box-Plot

La verdadera potencia del boxplot radica en su robustez frente a los valores extremos. Si utilizas un promedio matemático (la media) para evaluar el comportamiento de un sistema, un par de valores gigantescos pueden distorsionar todo el resultado. El boxplot, al basarse en la mediana y los cuartiles, no se deja engañar por esos extremos.

Un diagrama de caja (o boxplot) es una representación gráfica estandarizada que resume visualmente cómo se distribuye un conjunto de datos numéricos a través de sus cuartiles.

A diferencia de un histograma que muestra la frecuencia, el boxplot se centra en mostrar la dispersión, la tendencia central y, de manera crucial, aislar las anomalías.




os Bigotes (Mínimo y Máximo calculados): Son las líneas que se extienden hacia afuera de la caja. No representan necesariamente el valor más pequeño o más grande de todos tus datos, sino el límite de lo que se considera un comportamiento "normal".

Matriz de correlación

Una matriz de correlación es una tabla que muestra los coeficientes entre muchos pares de variables. Es una herramienta clave para el análisis exploratorio de datos (EDA).


	A	B	C	D	E	F	G	H	I
A	1.00								
B	0.51	1.00							
C	0.38	0.37	1.00						
D	0.57	0.22	0.09	1.00					
E	0.22	0.57	0.10	0.68	1.00				
F	0.11	0.11	0.46	0.59	0.58	1.00			
G	0.56	0.22	0.11	0.67	0.42	0.33	1.00		
H	0.23	0.58	0.12	0.43	0.66	0.34	0.67	1.00	
I	0.11	0.11	0.45	0.34	0.32	0.58	0.58	0.60	1.00




Interpretar un coeficiente o una matriz de correlación va mucho más allá de observar si un número es cercano a 1 o a -1. Para realizar un análisis riguroso y evitar conclusiones erróneas, una persona debe considerar los siguientes factores críticos:

- 1) Correlación no implica causalidad:** Este es el principio fundamental de la estadística. Que dos variables (X e Y) varíen de forma simultánea y predecible solo significa que comparten una tendencia, no que una sea la causa de la otra.
- 2) Limitación de la linealidad:** El coeficiente de correlación más utilizado (el de Pearson) solo mide relaciones lineales (en línea recta). Si la relación entre dos variables tiene forma de curva (por ejemplo, una "U" invertida o una curva exponencial), el coeficiente de Pearson puede ser cercano a cero, sugiriendo erróneamente que no hay relación cuando en realidad existe una conexión muy fuerte pero no lineal.
- 3) El impacto destructivo de los valores atípicos (Outliers):** Un solo dato extremo o inusual puede alterar por completo el coeficiente de correlación. Un outlier puede inflar artificialmente una correlación que en realidad es débil, o por el contrario, puede hacer que una correlación sólida parezca inexistente. Por esta razón, siempre se debe acompañar la matriz de correlación con un gráfico de dispersión (scatterplot) para visualizar la distribución real de los puntos.


Histogramas: Tendencia y tipo de distribución




Distribución normal




Distribución sesgada
a la izquierda




Distribución sesgada
a la derecha



Distribución uniforme



Distribución bimodal




Distribución multimodal

Distribuciones, Histogramas y Box-Plots


Uniforme




Unimodal



Unimodal 2




Bimodal




Valores de los datos

Mediante el uso de histogramas tradicionales, se ilustran comportamientos comunes en conjuntos de datos del 0 al 100: la distribución uniforme, caracterizada por una frecuencia constante y plana; las distribuciones unimodales, que concentran la mayor parte de sus observaciones en torno a un único pico central; y la distribución bimodal, la cual exhibe dos picos diferenciados que suelen delatar la presencia de dos subgrupos distintos mezclados en una misma muestra.


Los valores reales en una distribución



Cómo un histograma mostraría los valores (rotado)



Cómo un diagrama de caja mostraría los valores




Se alinean verticalmente los valores reales de la distribución, evidenciando las zonas de mayor densidad y los elementos aislados; posteriormente, este comportamiento se traslada a un histograma rotado horizontalmente donde la longitud de las barras refleja fielmente dicha acumulación. Esta progresión demuestra de qué manera la dispersión y la concentración de las observaciones individuales determinan de forma directa la estructura final del gráfico de caja.

La caja central delimita el rango intercuartílico, que resguarda el 50% central de la información, marcando explícitamente los percentiles 25, 50 (la mediana) y 75. Desde los bordes de esta estructura se extienden los llamados bigotes, cuya longitud llega hasta el punto no atípico más lejano dentro de un límite de 1.5 veces el rango intercuartílico, dejando como puntos suspendidos en el exterior a los valores atípicos o outliers, que representan anomalías inusualmente distantes del resto del grupo.

Asimetría (Skewness)


Conocer la asimetría de una variable es fundamental porque nos advierte cuándo el promedio tradicional (la media) es un indicador engañoso. Si un conjunto de datos es muy asimétrico, los valores extremos actúan como un imán y "arrastran" la media matemática hacia ellos, alejándola del punto donde realmente se concentra la mayoría de la información. Al detectar asimetría, sabemos de inmediato que debemos apoyarnos en otros indicadores, como la mediana o los percentiles, para comprender el comportamiento típico y real de ese modelo.

Simétrica




Es una campana perfecta, este balance establece una línea base teórica sumamente predecible, asumiendo que las desviaciones hacia arriba o hacia abajo del promedio tienen exactamente la misma probabilidad de ocurrir, lo cual simplifica enormemente la calibración inicial de cualquier sistema de análisis antes de enfrentarse a la realidad de los datos de producción.

Sesgada a la izquierda (negativamente)




La asimetría negativa o sesgada a la izquierda invierte esta dinámica, presentando una concentración masiva de datos en los rangos superiores y dejando una cola que se arrastra hacia los valores más bajos, lo que empuja la media por debajo de la mediana.

Sesgada a la derecha (positivamente)




La asimetría positiva o sesgada a la derecha dibuja una curva donde la mayor concentración de datos se apila en los valores bajos (la moda), mientras que una cola larga y delgada se extiende hacia la derecha, arrastrando a la media matemática por encima de la mediana.

Asimetría: Box-Plots vs Histogramas



Curtosis

La curtosis es una medida estadística que describe cómo se distribuyen los datos alrededor de la media, enfocándose específicamente en el grosor de las "colas" de la distribución y, por ende, en la agudeza de su pico central.



Distribución mesocúrtica representa el estándar estadístico por excelencia, dibujando la clásica curva normal donde las observaciones se agrupan de manera simétrica y equilibrada en torno a la media. En este escenario, la probabilidad de encontrar valores extremos en las colas es moderada y matemáticamente predecible.


Distribución leptocúrtica se distingue por presentar un pico central mucho más agudo acompañado de colas densas o "pesadas", lo que transforma radicalmente el panorama analítico al evaluar riesgos o perfilar comportamientos. Esta estructura matemática indica que, aunque la enorme mayoría de los datos orbita muy cerca del promedio, las desviaciones extremas y anómalas ocurrirán con una frecuencia significativamente mayor a la esperada.

Distribución platicúrtica se manifiesta a través de una curva achatada y ancha, caracterizada por tener colas extremadamente delgadas que denotan una ausencia notable de elementos fuera de lo común. En esta configuración, la información tiende a distribuirse de forma más uniforme a lo largo del espectro en lugar de aglomerarse en el centro, creando un ecosistema estadístico altamente estable donde la aparición de eventos atípicos de alto impacto es improbable, lo que permite relajar la agresividad matemática y confiar en una varianza mucho más segura y controlada.


En términos prácticos, la curtosis nos dice qué tan probables son los valores extremos o atípicos (outliers) en un conjunto de datos en comparación con una distribución normal.

Valores atípicos / extremos

Un valor extremo o valor atípico (outlier) es una observación que se desvía drásticamente del patrón general de un conjunto de datos. En el análisis de datos, estos valores no son simples errores; con frecuencia representan las señales más importantes dentro del "ruido", indicando eventos extraordinarios, fraudes o fallos estructurales que los modelos analíticos deben aislar o comprender.




La media es frágil ante eventos extremos. Ese pequeño grupo de anomalías tiene la fuerza matemática suficiente para arrastrar la Media muy a la derecha, separándola drásticamente de la Mediana y la Moda. Si un modelo de perfilamiento de comportamiento dependiera de esa media matemática pura para establecer sus líneas base, generaría una cascada de falsos positivos al evaluar el comportamiento típico.



Se puede clasificar a los valores atípicos según su estructura, un concepto vital al diseñar sistemas que rastrean variables continuas y vectores de estado. **Valores normales (inliers):** Es la nube densa de puntos en la parte inferior izquierda. Representa el comportamiento base esperado y predecible del sistema. **Valores atípicos (outliers) globales/puntuales:** Son esos dos puntos aislados en la parte inferior derecha. Representan anomalías individuales y extremas. **Valores atípicos colectivos:** Esta es la anomalía más compleja de modelar. Observa el grupo encerrado en la parte superior izquierda. Aunque sus valores en el eje X son normales, en el eje Y están completamente desviados, y lo más importante: forman un grupo estructurado.


Abordaje de valores atípicos



Detección de valores atípicos con Z-Score

El Z-Score es una métrica estadística que indica a cuántas desviaciones estándar se encuentra un punto de datos específico respecto al promedio o media de todo el grupo.


En la práctica, esta técnica permite establecer umbrales matemáticos claros (por ejemplo, "marcar cualquier registro donde $|z| > 3$ ") para automatizar la detección de anomalías en lugar de depender de reglas manuales.



Zona "Valores atípicos" (Más allá de $z = -3$ y $z = 3$): Las colas extremas de la gráfica. La probabilidad de que un dato legítimo caiga aquí es extremadamente baja (generalmente menos del 0.3%). En la ciencia de datos, cualquier valor en esta zona se considera un "outlier" o valor atípico, lo que levanta una alerta porque sugiere una anomalía severa, un error de medición o un evento extraordinario.

Isolation Forest

Isolation Forest (Bosque de Aislamiento) es un algoritmo de aprendizaje automático no supervisado, diseñado específicamente para la detección de anomalías.





1 Anomalías son fáciles de aislar: Como están lejos del grupo principal y en zonas poco densas, un corte aleatorio tiene una alta probabilidad de separarlas del resto muy rápidamente. Requieren muy pocas particiones para quedar solas.

2 Datos normales son difíciles de aislar: Al estar agrupados densamente en el centro, se necesitan muchísimos cortes aleatorios minuciosos para lograr separar un punto normal de todos sus vecinos.

Isolation Forest

Paso a paso de cómo un único Árbol de Aislamiento (iTree) divide el espacio bidimensional para encontrar anomalías. El principio matemático central del modelo es que la anomalía queda aislada de forma casi instantánea, mientras que el valor normal requirió




1 Las líneas discontinuas representan los cortes aleatorios, rectos y ortogonales, realizados por el algoritmo. Para separar los puntos que están más agrupados en el lado izquierdo, el algoritmo tuvo que seguir trazando líneas (primero horizontal en $Y=9$, luego vertical en $X=7$ y $X=6$, etc.), creando "cajas" cada vez más pequeñas. El punto gris (7, 7) queda aislado en su propio cuadrante solo después de múltiples divisiones.

2 Traduce esos cortes geométricos en un árbol de decisión lógico, revelando la métrica clave: la profundidad. El camino de la anomalía (Nodo Negro): En la raíz del árbol de la derecha, la primera regla es evaluar si el valor X es mayor o menor que 11. El punto (13, 11) es el único que cumple con la condición de estar a la derecha, por lo que se convierte inmediatamente en una "hoja" final del árbol. Se aísla rápidamente en una profundidad de 1. El camino del dato normal (Nodo Gris): Para que el algoritmo logre aislar el punto (7, 7), debe hacer un recorrido largo a través de las ramas evaluando múltiples condiciones para finalmente separarlo de su vecino más cercano, el punto (8, 4). Debido a esto, termina en la parte inferior del árbol con una profundidad de 4.


Local Outlier Factor (LOF)

Es un método de aprendizaje automático no supervisado utilizado para la detección de anomalías. En lugar de evaluar los datos a nivel global, LOF mide la desviación de la densidad local de un punto específico en comparación con sus vecinos más cercanos. En términos simples: si un dato se encuentra en una región mucho menos densa o más aislada que los puntos que lo rodean directamente, el algoritmo lo identifica como una anomalía o "outlier".




$K = 3$


Determinar el número de K



RD = Distancia de Alcanzabilidad



Calcular la Distancia de Alcanzabilidad Local para cada punto de datos



Calcular LOF


El primer paso consiste en definir un parámetro K, que representa la cantidad de vecinos más cercanos que se tomarán en cuenta para analizar un dato. En el primer panel de la imagen, se evalúa el punto A con un valor de $K = 3$. El círculo traza el radio necesario para abarcar exactamente a esos tres vecinos más cercanos (B, C y D), lo que define su vecindario local.

Calcula Reachability Distance (RD). Esta es una métrica de distancia ajustada que indica cuán "lejos" está un punto de otro, pero utilizando un límite inferior basado en la distancia del vecindario. Esto sirve para evitar fluctuaciones drásticas y suavizar el ruido estadístico. En la gráfica, se muestran los vectores que miden esta distancia hacia puntos dentro del límite (como D) y fuera de él (como A').


Calcula LRD para el punto A. Esto se logra promediando las distancias de alcanzabilidad calculadas en el paso anterior hacia todos sus vecinos (las flechas verdes hacia B, C y D) y tomando la inversa de ese promedio. Básicamente, este paso responde a la pregunta: ¿Qué tan apretados o dispersos están los datos alrededor del punto A?

El último paso compara la densidad del punto A con las densidades de sus vecinos (B, C y D), como lo sugieren los círculos superpuestos. El factor LOF es el ratio o proporción entre estas densidades: Si el valor LOF es cercano a 1, la densidad del punto es similar a la de sus vecinos (es un dato normal o "inlier"). Si el valor LOF es mayor a 1, significa que la densidad del punto es notablemente inferior a la de sus vecinos, lo que lo clasifica definitivamente como un valor atípico local.

Datos desbalanceados: Enfoques de tratamiento



Compromiso entre precisión y exhaustividad (Trade-off)




Zona de solapamiento: El espacio donde ambas curvas se cruzan indica que hay observaciones de ambas clases que comparten características (valores) muy similares. Es en esta intersección donde los modelos de clasificación cometen errores.

Frontera de decisión: Representa el umbral (o hiperplano) que el algoritmo utiliza para separar y clasificar las predicciones. Todo lo que cae a su izquierda se clasificaría como clase mayoritaria, y lo que cae a su derecha como clase minoritaria.


Datos dentro del margen: Representa el "margen" alrededor de la frontera de decisión. Este concepto es central en algoritmos como las Máquinas de Vectores de Soporte (SVM). El área sombreada contiene los datos (de ambas clases) que son más difíciles de clasificar porque están en la frontera o cruzando el límite hacia el territorio de la clase opuesta.

El gráfico captura visualmente el compromiso entre precisión y exhaustividad (Trade-off). Debido a que las clases se solapan: Falsos Positivos vs. Falsos Negativos: Cualquier dato de la clase mayoritaria que caiga a la derecha de la línea central será un falso positivo. Cualquier dato de la clase minoritaria que caiga a la izquierda será un falso negativo. Ajuste del Umbral: Si se mueve la frontera de decisión (la línea central) hacia la izquierda para capturar más de la clase minoritaria, inevitablemente se incluirá más área de la clase mayoritaria, aumentando los falsos positivos. Si se mueve a la derecha, ocurre lo contrario. Los "datos dentro del margen" son esencialmente la fuente de error del modelo y el área donde las técnicas de optimización deben enfocarse para mejorar la separación de las clases.

Datos desbalanceados: Problemas




Datos desbalanceados: Métodos y técnicas algorítmicas




SMOTE: Synthetic Minority Oversampling Technique

Es un algoritmo clave en el preprocesamiento de datos de aprendizaje automático, utilizado específicamente para abordar el problema de los conjuntos de datos desequilibrados—un escenario muy común al entrenar modelos para la detección de anomalías o el monitoreo de transacciones.



Baja diversidad con SMOTE

En conjunto de datos original se observa un desequilibrio claro. La clase mayoritaria está representada por los cuadrados blancos y la clase minoritaria por los círculos negros. En lugar de simplemente duplicar los círculos negros existentes, SMOTE identifica las relaciones espaciales entre ellos. Las líneas punteadas muestran cómo el algoritmo conecta los puntos de la clase minoritaria cercanos entre sí. El resultado final es un conjunto de datos remuestreado, el algoritmo ha generado nuevos círculos negros a lo largo de las conexiones previamente establecidas, equilibrando la cantidad de datos entre ambas clases.




Interpolación con SMOTE

El algoritmo toma un punto específico de la clase minoritaria (marcado como x_1). Identifica cuáles son los k vecinos más cercanos a x_1 que también pertenecen a la clase minoritaria (en este caso, los puntos x_2 , x_3 , x_4 , x_5 y x_6). Interpolación: Se trazan vectores entre x_1 y cada uno de esos vecinos. Se generan las nuevas muestras sintéticas (a, b, c, d, e). Estos nuevos puntos no se colocan al azar en el espacio, sino que se ubican en posiciones aleatorias estrictamente a lo largo de las líneas que conectan x_1 con sus vecinos.


Valores faltantes

Nulos, ceros o espacios vacíos se consideran valores faltantes.




Imputación de valores faltantes

La imputación de valores faltantes es el proceso estadístico y de preparación de datos que consiste en reemplazar los datos nulos, vacíos o ausentes (a menudo representados como NaN, Null o NA en programación) por valores estimados o calculados.




Estrategia	Ventaja Principal	Desventaja Principal
Media / Mediana	Rápido, sencillo y funciona bien si faltan pocos datos.	Reduce artificialmente la varianza de la distribución (los datos se agrupan en el centro).
Borrar Filas	Mantiene un conjunto de datos 100% puro y real.	Destruye información útil en otras columnas de la misma fila.
Predictivo (KNN/ Regresión)	Altamente preciso; mantiene las relaciones complejas entre variables.	Computacionalmente costoso y requiere más tiempo de desarrollo.

Imputación de valores faltantes




Multicolinearidad

Este concepto se aplica principalmente en modelos de regresión múltiple. La multicolinealidad ocurre cuando dos o más variables independientes (las que usas para predecir) están altamente correlacionadas entre sí.




Curva Azul (Menor Multicolinealidad): Es alta y estrecha. Esto es lo ideal. Significa que la varianza es baja y el modelo está muy seguro del valor real del coeficiente. Tu estimación es precisa. **Curva Naranja (Mayor Multicolinealidad):** Es baja y ancha. Al estar las variables altamente correlacionadas, el modelo se "confunde" y no puede distinguir qué variable está aportando realmente la información. Como resultado, la varianza del coeficiente se dispara (la curva se aplana), haciendo que la estimación sea imprecisa, inestable y poco confiable.



Multicolinealidad


La multicolinealidad causa redundancia, lo que conduce a resultados inestables y dificulta la interpretación.

Baja Correlación: X1 vs X2




Baja Correlación - Sin Multicolinealidad

Alta Correlación: X1 vs X3




Alta Correlación - Multicolinealidad

Multicolinearidad



Tamaño del Efecto: d de Cohen

A medida que el valor de la d de Cohen aumenta, las medias de los grupos se alejan y la zona en la que se confunden (superposición) se reduce drásticamente, confirmando que el efecto analizado es de gran magnitud.




Los promedios de ambos grupos están muy cerca uno del otro. En la práctica, aunque estadísticamente haya una diferencia, es tan pequeña que sería difícil distinguir a un individuo (o dato) de un grupo frente al otro.

La distancia entre los promedios aumenta y las curvas comienzan a separarse. La diferencia entre los dos grupos es ahora mucho más clara y el efecto de lo que se esté evaluando empieza a ser evidente.

Los promedios están marcadamente separados. En este escenario, los grupos son claramente distintos. La intervención, característica o cambio que separa a un grupo del otro tiene un impacto sustancial, fuerte y fácilmente observable.

Multicolinealidad


Variables ligeramente correlacionadas



Variables altamente correlacionadas


Sin multicolinealidad

Sin correlación de las variables independientes







Multicolinealidad

Alta correlación de las variables independientes




Tarea: Clasificación

Geométricamente hablando, una forma común de ver la tarea de clasificación en dos dimensiones consiste en encontrar una línea de separación (o, de manera más general, una curva de separación) que separe con precisión dos tipos de datos.




La figura ilustra el concepto de un modelo lineal o clasificador utilizado para realizar la clasificación en un conjunto de datos de prueba bidimensional.


Tarea: Clasificación



Clasificación multiclase




Detección multiclase



Una sola clase

Partición estratégica de un conjunto de datos



El conjunto de datos para aprendizaje supervisado está dividido en **Entradas** (las variables o características que el sistema observa, como la frecuencia temporal o el monto de una operación) y los **Objetivos** (el resultado que queremos que el modelo aprenda a predecir, como identificar si el patrón corresponde a un comportamiento normal o a una anomalía estructurada). Si un algoritmo procesa toda esta información de golpe, corre el riesgo de simplemente "memorizar" el histórico, volviéndose inútil al enfrentarse a escenarios futuros. Para evitar esto, los datos se dividen en tres subconjuntos aislados.


El **subconjunto de entrenamiento**, es la porción más grande de los datos (usualmente entre el 60% y el 80%). Es aquí donde el núcleo matemático del modelo analiza los ejemplos, ajusta sus pesos internos y construye su lógica predictiva base.

El **subconjunto de validación**; durante el proceso de entrenamiento, el modelo se evalúa periódicamente contra este segundo bloque para ajustar configuraciones internas delicadas (hiperparámetros). Esta validación cruzada actúa como un calibrador dinámico que previene el "sobreajuste" (overfitting), asegurando que el modelo esté aprendiendo a generalizar las reglas subyacentes del comportamiento en lugar de memorizar el "ruido" específico de los datos con los que fue entrenado.

El **subconjunto de prueba** es la prueba de fuego y debe mantenerse estrictamente oculto y aislado durante todas las fases previas de desarrollo. Una vez que la arquitectura del modelo está definida, calibrada y optimizada, se expone por primera y única vez a este bloque de datos. Evaluar el rendimiento en esta etapa es la única métrica verdaderamente honesta de cómo se comportará el sistema en producción ante eventos completamente inéditos.

Validación cruzada

Permite asegurar que el modelo sea capaz de generalizar y funcionar bien con datos nuevos y no vistos, en lugar de simplemente memorizar los datos con los que fue entrenado.




- 1 Validación de dejar uno fuera** (Leave-One-Out Cross-Validation), donde se aísla una sola imagen de todo el conjunto para evaluar la clasificación, utilizando absolutamente todo el resto de las muestras para entrenar el modelo.
- 2 Validación de dejar un paciente fuera** (Leave-One-Subject-Out Cross-Validation), un enfoque vital cuando se tienen múltiples registros por individuo; aquí se reservan en bloque todas las imágenes correspondientes a un mismo paciente para la fase de prueba, entrenando el algoritmo exclusivamente con los pacientes restantes para medir cómo generaliza el modelo ante sujetos completamente nuevos.
- 3 Validación cruzada de k-iteraciones** (K-Fold Cross-Validation), en la cual los datos se dividen aleatoriamente en varios subconjuntos o "pliegues", seleccionando iterativamente un grupo mixto de imágenes como conjunto de prueba mientras las demás conforman las muestras de entrenamiento. el algoritmo exclusivamente con los pacientes restantes para medir cómo generaliza el modelo ante sujetos completamente

En lugar de dividir el conjunto de datos una sola vez en una parte para "entrenar" y otra para "probar" (lo cual puede dejar fuera información valiosa o dar resultados sesgados por casualidad), la validación cruzada repite este proceso de división y evaluación múltiples veces.

Validación cruzada

La validación cruzada es una técnica estadística robusta diseñada para evaluar la verdadera capacidad de generalización de un modelo predictivo. En lugar de realizar una única división estática de los datos históricos (donde una parte se usa para enseñar y otra para evaluar), esta metodología recicla el conjunto de información múltiples veces.




El proceso operativo sigue esta secuencia:

- 1) El bloque total de datos (que contiene tanto las entradas como los objetivos) se particiona en 5 segmentos o "pliegues" idénticos.
- 2) El modelo se entrena desde cero 5 veces distintas. En la 1ra iteración, el primer bloque (marcado en gris oscuro) se aísla como el Pliegue de Validación. El modelo se entrena exclusivamente con los 4 bloques restantes (el Pliegue de Entrenamiento) y luego se expone al bloque de validación para evaluar su capacidad de detectar patrones, generando una métrica de rendimiento. En la 2da iteración, el rol de validación se desplaza al segundo bloque.
- 4) El modelo se vuelve a entrenar con los otros 4 bloques y se evalúa nuevamente para obtener el rendimiento. Esta rotación metódica continúa hasta que los 5 bloques hayan servido exactamente una vez como prueba de fuego. K-Fold garantiza que cada línea de datos históricos haya sido evaluada.
- 5) Al final del proceso, agrupa calcula el promedio aritmético de las iteraciones. Si las métricas individuales oscilan violentamente entre iteraciones, indica que el filtro predictivo es inestable; si el promedio es alto y las variaciones son mínimas, el algoritmo está listo para enfrentarse a flujos de datos en producción.

El objetivo es asegurar que la precisión del modelo sea consistente y no el resultado de haber memorizado un fragmento de datos "fácil" o particular.

Evaluación: Curva ROC

Curva ROC (del inglés Receiver Operating Characteristic o Característica Operativa del Receptor). Es una representación gráfica fundamental utilizada en el aprendizaje automático para evaluar y visualizar el rendimiento de los modelos de clasificación binaria a través de diferentes umbrales de decisión.



Eje Y (TPR o Sensibilidad): Representa la Tasa de Verdaderos Positivos (True Positive Rate). Nos indica: de todos los casos que realmente son positivos, ¿qué porcentaje logró identificar el modelo de forma correcta? Lo ideal es que este valor llegue a 1 (100%).

Eje X (FPR o 1 - especificidad): Representa la Tasa de Falsos Positivos (False Positive Rate). Nos indica: de todos los casos que realmente son negativos, ¿qué porcentaje el modelo clasificó erróneamente como positivos (falsas alarmas)? Lo ideal es que este valor se mantenga en 0.

Líneas y Zonas Clave

Línea diagonal roja discontinua ("Adivinanza aleatoria"): Representa una base de referencia (baseline). Un modelo cuya curva o puntos caigan sobre esta línea es equivalente a lanzar una moneda al aire; no tiene ninguna capacidad predictiva real. Esquina superior izquierda ("Clasificación perfecta"): Es el "santo grial" del modelo (coordenada 0, 1). Significa que detecta absolutamente todos los casos positivos (Sensibilidad = 1) sin cometer un solo error de falsa alarma (FPR = 0). La Curva Azul y el Área Rayada: La línea azul sólida muestra cómo se comporta un modelo específico. El área rayada debajo de ella representa una métrica crucial llamada AUC (Área Bajo la Curva). Como indica la flecha "Mejor", cuanto más se abombe la curva hacia la esquina superior izquierda, mayor será el área y mejor será la capacidad del modelo para distinguir entre clases.

Los puntos dispersos representan el rendimiento del modelo utilizando diferentes configuraciones o umbrales estrictos: Punto C (arriba a la izquierda): Es un rendimiento excelente. Tiene una alta sensibilidad (detecta alrededor del 75% de los positivos) con una tasa muy baja de falsos positivos (cerca del 12%). Punto A: Es un rendimiento decente, pero inferior a C. Detecta poco más del 60% de los positivos, pero genera casi un 30% de falsas alarmas. Punto D (abajo a la derecha): Se encuentra en la zona "Peor". Su rendimiento es inferior a la adivinanza aleatoria. Irónicamente, si un modelo está constantemente por debajo de la línea diagonal (se equivoca sistemáticamente), a menudo puedes simplemente invertir sus predicciones (cambiar los "sí" por "no") para convertirlo en un modelo con buen rendimiento.