

UNIVERSIDAD CENFOTEC

Escuela de Tecnologías de Información

Curso: Aprendizaje Automático

Proyecto

Análisis Exploratorio, Clasificación y Clustering con Scikit-Learn

Información general

Modalidad:	Trabajo individual o en parejas (máx. 2 personas)
Ponderación:	25% de la nota final del curso
Entrega:	Notebook .ipynb (Google Colab) + Informe escrito (.docx o .pdf)
Fecha límite:	Ver plataforma virtual del curso
Herramienta:	Python 3 + Scikit-Learn (sin PySpark)

1. Objetivo General

Aplicar de forma integrada las técnicas de preprocesamiento, análisis exploratorio de datos (EDA), clasificación supervisada y agrupamiento no supervisado usando Scikit-Learn sobre dos datasets del dominio de la salud y el comercio minorista. El estudiante debe demostrar dominio del ciclo completo de un proyecto de aprendizaje automático: desde la carga y limpieza de datos hasta la evaluación e interpretación de modelos.

2. Datasets de la Tarea

2.1 Parte I — Clasificación: Heart Disease Dataset

Fuente: adaptado del repositorio UCI Machine Learning Repository (Cleveland Heart Disease).

Descripción: 303 pacientes. Target: 0 = sin enfermedad cardíaca, 1 = con enfermedad.

Variable	Tipo	Descripción
age	Numérica	Edad del paciente (años)
sex	Binaria	1 = masculino, 0 = femenino
cp	Catégorica	Tipo de dolor en el pecho (0-3)
trestbps	Numérica	Presión arterial en reposo (mm Hg)
chol	Numérica	Colesterol sérico (mg/dl)
fbs	Binaria	Glucosa en ayunas > 120 mg/dl (1=sí)
restecg	Catégorica	Electrocardiograma en reposo (0-2)
thalach	Numérica	Frecuencia cardíaca máxima alcanzada
exang	Binaria	Angina inducida por ejercicio (1=sí)

oldpeak	Numérica	Depresión del segmento ST
slope	Categoría	Pendiente del segmento ST (0-2)
ca	Numérica	Vasos principales (0-3) — contiene nulos
thal	Categoría	Tipo de talasemia (1-3) — contiene nulos
target	Binaria	Variable objetivo: 1=enfermedad, 0=sin enfermedad

2.2 Parte II — Clustering: Mall Customers Dataset

200 clientes de un centro comercial. Objetivo: descubrir segmentos de clientes.

Variable	Tipo	Descripción
CustomerID	Identificador	ID único (no usar en el modelo)
Genre	Categoría	Género: Male / Female
Age	Numérica	Edad del cliente (años)
Annual_Income_k	Numérica	Ingreso anual en miles de USD
Spending_Score	Numérica	Puntuación de gasto (1-100)

3. Parte I — Clasificación (60 puntos)

3.1 Carga y exploración inicial (5 pts)

- Leer el CSV con pandas. Mostrar primeras 10 filas, tipos de datos y dimensiones.
- Verificar valores nulos por columna e identificar variables con datos faltantes.
- Justificar por qué ciertos valores cero son médicamente inválidos.

3.2 Análisis Exploratorio de Datos (15 pts)

- Estadísticas descriptivas con `.describe(include="all")`.
- Distribución de la variable objetivo — gráfico de barras con porcentajes.
- Histogramas de todas las variables numéricas en una grilla.
- KDE por clase (`target=0` vs `target=1`) para variables continuas.
- Cálculo de la *d* de Cohen por variable (tamaño del efecto entre grupos).
- Curtosis de cada variable numérica — clasificar e interpretar.
- Mapa de calor de correlaciones de Pearson (`pandas.corr()` + `seaborn`).
- Boxplots de variables numéricas para detección visual de outliers.

3.3 Tratamiento de valores faltantes (5 pts)

- Estrategia A: imputación con la media usando `SimpleImputer` de `sklearn`.
- Estrategia B: eliminación de filas con nulos (`dropna`).
- Comparar tamaño resultante y justificar cuál se usa para el modelado.

3.4 Detección y manejo de outliers (5 pts)

- Método IQR con pandas/numpy: calcular Q1, Q3 y límites por variable.
- Cuantificar el porcentaje de registros afectados por columna.

- Boxplots antes y después del tratamiento.

3.5 Preparación de features y Pipeline (5 pts)

- Construir Pipeline de sklearn: SimpleImputer → StandardScaler.
- Split estratificado 80/20 con train_test_split(stratify=y).
- Verificar distribución de clases en train y test.

3.6 Modelado — tres algoritmos de clasificación (20 pts)

- Algoritmo 1: Decision Tree Classifier
 - Probar max_depth = 3, 5 y 10. Analizar overfitting.
 - Visualizar el árbol con sklearn.tree.plot_tree (profundidad ≤ 4).
- Algoritmo 2: Random Forest Classifier
 - Usar n_estimators ≥ 100. Graficar importancia de variables.
 - Comparar con el Decision Tree — ¿qué aporta el ensemble?
- Algoritmo 3: MLP Classifier (MLPClassifier de sklearn)
 - Dos arquitecturas: hidden_layer_sizes=(64,32) y (128,64,32).
 - Documentar el efecto del parámetro solver (adam vs sgd).

3.7 Evaluación y comparación de modelos (5 pts)

- Calcular: Accuracy, F1 (macro), Precisión, Recall, AUC-ROC para cada modelo.
- Curva ROC del mejor y peor modelo superpuestas en una figura.
- Tabla comparativa ordenada por AUC-ROC.
- Validación cruzada K-Fold (k=5) con cross_val_score sobre el mejor modelo.
- Matriz de confusión del mejor modelo con heatmap de seaborn.
- Discutir trade-off Precisión vs Recall en contexto clínico.

4. Parte II — Clustering (40 puntos)

Trabjará sobre mall_customers.csv. La columna _true_cluster NO debe usarse durante el clustering — solo al final para validar los resultados.

4.1 EDA del dataset de clustering (8 pts)

- Estadísticas descriptivas, histogramas y boxplots de variables numéricas.
- Codificación de Genre con pd.get_dummies() o LabelEncoder.
- Mapa de calor de correlaciones entre variables numéricas.
- Calcular skewness y aplicar transformación log donde corresponda.
- Detección y remoción de outliers con método IQR.

4.2 Preparación de features (4 pts)

- Escalar variables con StandardScaler.

- Calcular el índice de Hopkins para verificar aptitud del dataset para clustering.

4.3 Selección de k — Elbow + Silhouette (8 pts)

- KMeans para k=2..10: graficar inercia vs k (método del codo).
- Silhouette Score para cada k — panel comparativo con el codo.
- Justificar la elección de k combinando ambos criterios.

4.4 Tres algoritmos de clustering (12 pts)

- Algoritmo 1: KMeans
- Algoritmo 2: AgglomerativeClustering (jerárquico)
 - Probar linkage = ward, complete y average. Visualizar dendrograma.
- Algoritmo 3: GaussianMixture (GMM)
 - Comparar BIC vs AIC para selección del número de componentes.
- Para cada algoritmo: Silhouette Score y tamaño de cada cluster.

4.5 Visualización con TSNE (4 pts)

- Reducir con PCA (curva de varianza explicada, justificar n_components).
- Graficar los 3 algoritmos en el mismo plano TSNE (3 paneles comparativos).

4.6 Perfilado e interpretación (4 pts)

- Perfil de gasto promedio por cluster en escala original.
- Heatmap normalizado del perfil de clusters.
- Tabla cruzada clusters encontrados vs _true_cluster.
- Asignar nombre de negocio a cada cluster y justificarlo.

5. Informe Escrito (incluido en la ponderación)

Máximo 15 páginas (sin gráficos ni código). Debe contener:

- Portada: nombre(s), carné(s), fecha, título.
 - Resumen ejecutivo (máx. ½ página).
 - Parte I: justificación de preprocesamiento, comparación de modelos, interpretación clínica y discusión del trade-off Precisión/Recall.
 - Parte II: justificación de k, descripción de segmentos, comparación de algoritmos.
 - Conclusiones generales (máx. 1 página).
 - Referencias en formato APA.
-

6. Rúbrica de Evaluación

Criterio	Pts	Descripción del nivel sobresaliente
Carga y EDA clasificación	15	EDA completo: d Cohen, curtosis, KDE,

		correlaciones
Tratamiento de faltantes	5	Dos estrategias, comparación de impacto
Outliers IQR	5	IQR correcto, % cuantificado, boxplots
Pipeline y split estratificado	5	Pipeline sklearn, split, verificación de clases
Decision Tree	7	Tres profundidades, plot_tree, overfitting
Random Forest	7	n_estimators≥100, importancia, vs DT
MLP Classifier	6	Dos arquitecturas, efecto del solver
Evaluación clasificación	10	Todas las métricas, ROC, CV, matriz
EDA clustering	8	EDA completo, encoding, log si aplica
Selección de k	8	Elbow + Silhouette, panel, justificación
Tres clusterers	12	KMeans + Agglomerative + GMM, dendrograma, BIC
TSNE y perfilado	8	PCA+TSNE, 3 paneles, heatmap, nombres
Calidad del informe	4	Redacción, conclusiones, APA
TOTAL	100	

7. Restricciones y Buenas Prácticas

Restricciones obligatorias

- Todo debe realizarse con Python estándar y Scikit-Learn.
- La columna `_true_cluster` NO debe usarse durante el clustering (solo validación final).
- El notebook debe ejecutarse sin errores de principio a fin antes de la entrega.
- Cada celda de código debe tener al menos un comentario explicativo.
- No usar `CrossValidator` para K-Fold — usar `cross_val_score` directamente.

Buenas prácticas evaluadas

- Usar Pipeline de sklearn para encadenar preprocesamiento y modelado.
- Fijar `random_state` en todos los modelos para reproducibilidad.
- Documentar cada decisión de preprocesamiento con su impacto cuantificado.
- Nombrar variables de forma descriptiva y consistente en todo el notebook.
- Incluir títulos descriptivos en todos los gráficos.

8. Formato de Entrega

- Comprimir en archivo .zip con nombre: Tarea2_Apellido1_Apellido2.zip
- El .zip debe contener:
 - Tarea2_Apellido1_Apellido2.ipynb — Notebook ejecutado con todos los outputs
 - Tarea2_Apellido1_Apellido2_informe.pdf — Informe escrito
 - heart_disease.csv — Dataset de clasificación
 - mall_customers.csv — Dataset de clustering
- El notebook debe estar completamente ejecutado. Un notebook sin outputs no se calificará.